CS5491 Group Project｜项目背景与研究动机

项目名称（更新版）：Signed FFN Layer-Order Context for Neural Spectral Capacity
阅读对象：小组全体成员｜研究方向沟通稿（不是正式提交的 Proposal）
版本：2026-10-13

> **一句话介绍**：我们不训练新的 Transformer，而是研究：只看已有 Transformer 的架构信息时，如果让 Neural Spectral Capacity（NSC）考虑「前面几层 FFN 的结构」，能否更准确地给候选模型排序，并在参数预算内选到表现更好的模型？更进一步，这种上下文权重应该递减还是递增？

1. 我们为什么要做这项研究？

1.1 现实问题：模型架构很多，逐个训练太贵

假设有 200 个候选 Transformer。它们的层数、隐藏维度、注意力头数和 FFN 宽度不完全相同。如果每个模型都重新训练，再比较效果，实验成本会非常高。

Neural Architecture Search（NAS，神经网络架构搜索）希望找到更好的网络设计。其中一个实用思路是先用**廉价的架构评分（heuristic）**给候选模型排序，再优先考虑高分架构。老师选定的主题正是：把 **Neural Spectral Capacity（NSC）**当作这样一种架构启发式指标，研究怎样让它更好地反映计算图结构。[1，第 1 页]

NSC 使用权重矩阵的**维度**与固定的**初始化约定**估计容量，然后将不同矩阵的贡献相加。其参考容量与矩阵奇异值有关，老师提供了对应的计算实现；核心作业**不需要推导 Marchenko–Pastur 定律，也不需要训练 Transformer**。[1，第 1–2 页]

请区分两件事：**NSC 是架构评分，不是模型实际 PPL；分数看起来合理，也不代表能预测训练后表现。**

1.2 Transformer 里的 FFN 为什么值得研究？

一个典型的双层 FFN 可以写为：

$$FFN(x)=W_2ReLU(W_1x+b_1)+b_2.$$

标准 FFN 对每个 Token 的隐藏向量分别执行**相同的可学习非线性变换**。其中，中间层宽度 f_l 决定第 l 层有多少个中间隐藏单元；隐藏维度记为 d_l。

更宽的 FFN 通常具有更多参数和更丰富的可表示函数，但**不能直接推出它的训练后 PPL 一定更低**。另一方面，Transformer 的各层按顺序组合：第二层处理的是第一层输出的表示。所以，「宽 FFN 放在哪一层」有可能包含原始加法指标没有利用的信息。

2. 我们发现的切入点：原始 NSC 不区分某些 FFN 重排

按照老师给定的 Baseline，可以把原始 NSC 简记为：

$$S_0=\sum_{l=1}^{L}(A_l+F_l),$$

其中 A_l 和 F_l 分别是第 l 层注意力投影与 FFN 投影的 **NSC 容量贡献**（不是注意力权重，也不是参数量）。具体数值由 Starter 的 nsc.py 定义和计算。

看一个只有两层的例子：

架构	第 1 层 FFN 宽度	第 2 层 FFN 宽度
A	256	512
B	512	256

如果两层的隐藏维度、Attention 等设置相同，仅交换 FFN 宽度，原始 NSC 的加法不受顺序影响：$F_{256}+F_{512}=F_{512}+F_{256}$。老师的示例里，这两个架构的**原始 NSC 均为 121.820170**；老师提供的位置加权示例则分别得到 **96.957958** 与 **85.772297**。[1，第 2 页]

这里要避免一个逻辑错误：**能给 A 和 B 打出不同分数，只证明指标具有“顺序敏感性”；还没有证明这种差异与真实 PPL 有关系。** 老师的重排示例本身没有对应的训练后性能标签。[1，第 2 页]

3. 我们的研究问题：前序 FFN 应该“折减”还是“增强”后续评分贡献？

原 Proposal 已经提出一种递减权重：**前面 FFN 的结构量越大，当前 FFN 容量的评分权重越小**。在讨论中，我们提出另一个同样需要验证的方向：**如果前面 FFN 提供了更丰富的处理条件，后续 FFN 的评分权重是否反而应该更大?**

这不是对真实网络机制的断言。 我们比较的是两类架构评分假设的**预测效果**；即使正向权重在实验中获胜，也不能证明真实网络内部发生了“增强”。

因此我们的完整问题是：

> **引入前序 FFN 层的结构信息，能否改善 NSC 对已训练 Transformer 的架构排序与预算选择？对同一种上下文特征，递减或递增的加权方向会不会影响结果?**

3.1 用什么描述“前序 FFN 结构”？

沿用现有 Proposal 的设计：

$$q_l=\frac{1}{2}d_l f_l s^4, Q_l=\sum_{j<l} q_j, s=0.02.$$

- q_l：由该层隐藏维度、FFN 宽度与固定初始化尺度计算的结构量。
- Q_l：**当前层之前**各层 q_j 的和，不包括当前层，因此第一层的 $Q_1=0$。
- q_l 的理论动机来自**独立高斯权重、各向同性输入、未归一化双层 ReLU 分支**下的二阶矩比例；在本项目涉及的 Post-LN 归档架构中，Q_l **只能视为结构代理特征（structural proxy）**，不能当成实际累积激活方差。[2，Method and mechanism checks]

3.2 一个参数，同时研究三个情形

我们设计统一的**有符号权重（Signed Context Weighting）**：

$$w(Q;\beta)=1+\frac{\beta Q}{1+|\beta| Q},$$

并把它用于 FFN 容量：

$$S(\beta)=\sum_l \left[A_l+w(Q_l;\beta)F_l\right].$$

- $\beta<0$（**递减**）：$w=1/(1+|\beta| Q)$；前序结构量越大，后续 FFN 评分权重越低（保留原 Proposal）。
- $\beta=0$（**基准**）：$w=1$；恢复原始 NSC，即删除新机制的消融实验（Ablation）。
- $\beta>0$（**递增**）：$w=1+\beta Q/(1+\beta Q)$；前序结构量越大，后续 FFN 评分权重越高。

为什么选它？因为它**保留了旧 Proposal 的递减公式**，只用 β 的正负号改变方向；当 $Q=0$ 时，权重为 1；当 $Q\geq 0$ 时，权重始终为正，且小于 2。对相同的 $|\beta|$，有 $w(Q;+|\beta|)+w(Q;-|\beta|)=2$，表示相对基准权重 1 的偏移幅度对称。**这种对称不代表最终排名变化也一定对称。**

这是**我们小组拟检验的新设计**，不是老师指定的 NSC 理论公式。数学上满足期望性质只是合理性的第一步，**真正的预测价值仍然必须由数据检验**。

4. 实验怎样回答问题？

老师提供的 Starter 基于 **200 个归档 decoder-Transformer 配置**，包括结构、报告的参数量以及训练后的 PPL：固定划分为 **100 个 Development + 100 个 Final**。我们不需要训练新模型，但必须承认归档架构存在深度、宽度、注意力设置、Embedding 等差异。[1，第 2 页]

4.1 先确认“公式如预期运行”

1. 用老师的 check_starter.py 和 evaluate.py 复现原始 NSC。
2. 在**没有 PPL 标签的两层 FFN 重排示例**上检查：$\beta=0$ 恢复原始 NSC，正负 β 的权重方向正确；再检查 $Q=0$ 与极限情况。
3. 这一步只检验**数学行为与实现是否正确**，不用于判断哪种设计预测得更好。

4.2 再确认“分数有没有实际预测价值”

在 **Development** 的 Validation PPL 上选择 $\beta\in\{0,\pm 0.1,\pm 1,\pm 10,\pm 100,\pm 1000\}$，明确选择规则后**冻结方法、代码和参数**；最终在 **Final** 的 Test PPL 上进行独立评估，不允许看到 Final 结果后继续调参。[2，Data and evaluation]

评价维度	需要回答什么	老师要求的做法
架构排序	高评分能否对应更低 PPL?	对 $-PPL$ 计算 Spearman ρ、Kendall τ_b，报告并列情况
预算选择	在资源受限时能否挑到更好的模型?	总参数上限 10M/20M/30M/50M；$k=1,3$；报告选中最优 PPL、Regret
基准对照	改进是否超过简单替代方法?	原始 NSC、老师的位置示例、参数量、参考 FLOPs、均匀随机选择
控制与稳健性	结果是否只是尺寸或配置差异造成?	相同隐藏宽度且参数量相差不超过 10% 的配对比较；相同 Embedding 配置的描述性比较；必要的重采样/敏感性检查

预算实验中，**Regret = 选中候选里的最低 PPL − 预算内全部可行模型的最低 PPL**，越接近 0 越好。我们还计划把**指数递减权重**作为函数形式敏感性对照，而不是只比较两个符号。[1，第 3 页；2，Data and evaluation]

5. 最后可能得到什么结论？

开发与最终评估观察	审慎的解释
$\beta<0$ 表现更好	在该归档面板与指定评估协议下，递减权重更有预测价值
$\beta>0$ 表现更好	递增方向值得进一步探索；旧 Proposal 的递减假

开发与最终评估观察	审慎的解释
	设不是唯一选择
$\beta=0$ 最好或差异不稳定	现有上下文特征／权重设计未显示稳定收益；这也是有效研究结果

不能声称：通过相关性直接证明 FFN 之间存在因果性的增强或抑制；或把不同配置模型的 PPL 差异全部归因于 FFN 顺序。老师的数据每个架构只有一次归档训练结果，不能估计训练随机种子造成的波动。[1，第 2–3 页]

6. 我们三个人应该先达成的共识

研究边界：只围绕 **FFN Layer-Order Context** 这一项机制；不额外训练新 Transformer，也不同时引入 MoE、KV Cache 等其他方向。核心目标是完成可复现的、符合课程规范的实验，而不是保证“新公式一定更好”。

初步分工：组员 A 负责 Starter 复现、原始 NSC 与数据审计；组员 B 负责排序、预算选择、统计与图表；方法负责人负责有符号权重实现、机制检查和报告整合。每人都应能解释自己负责模块的假设与局限。

最近的行动：先确认小组是否接受“带符号 β、正负方向对照”的新版 Proposal；获取并核对 nsc-starter.zip；约定开发集选参标准、评分结果的输出接口和代码合并规则。正式提交日期与格式以 Canvas 的 Course Project 页面为准；当前 Proposal 记录的提交节点为 **2026-10-15 23:59（北京时间）**。[2，文档注释]

小词典（读完这份文档应当认识）

- **Transformer**：由注意力、FFN 等模块组成的神经网络架构。
- **FFN / FFN Width**：逐 Token 的前馈非线性变换；Width 是中间层维度。
- **NSC**：根据架构规格估计的谱容量启发式评分，**不是**真实测试准确率。
- **Heuristic**：可快速计算、用于比较或指导搜索的近似指标。
- **PPL（Perplexity）**：语言模型常用评估量；在相同条件下通常越低越好。
- **Ablation**：删除新增机制，检查它是否真的带来价值；这里是 $\beta=0$。
- **Confounding（混杂因素）**：模型的规模、Embedding 等其他差异，可能同时影响评分与 PPL。

资料依据

[1] 课程教师提供：*Project Topic: Neural Spectral Capacity as a Heuristic for Architecture Design*，尤其第 1–3、5 页。

[2] 小组当前修订稿：*Signed FFN Layer-Order Context for Neural Spectral Capacity*（ProjectProposal-en-updated.md）。

说明：文中“原始 NSC 的定义、归档数据与核心评估要求”来自老师的材料；“有符号 β、递增方向比较”来自小组讨论，尚未在真实架构数据上得到验证。